

- Título: Variabilidad de la frecuencia cardíaca como indicador de estrés cognitivo

- Resumen: Se presenta un sistema que procesa señales crudas de ECG y EDA (Actividad Electrodermica) adquiridas mediante el kit BITalino, extrae características de Variabilidad de la Frecuencia Cardíaca (HRV/VFC) y de EDA, y clasifica el nivel de estrés cognitivo del usuario. El sistema se integra con un frontend en React ya existente mediante una API. Requisitos: Python 3.10+.

- Palabras clave: bitalino, hrv, estrés, vfc, eda, estrés cognitivo

- Introducción:

La variabilidad de la frecuencia cardíaca [HRV] refleja las fluctuaciones en el intervalo entre latidos consecutivos, resultado de la interacción dinámica entre el sistema nervioso simpático y parasimpático [1]. Diversas revisiones sistemáticas han encontrado asociación entre la HRV y el estrés psicológico, siendo el RMSSD la métrica más reportada, seguida de la relación LF/HF y la potencia HF [1]. Otras revisiones han estudiado la relación entre HRV y funciones cognitivas de forma longitudinal, encontrando que una mayor actividad parasimpática se asocia consistentemente con mejor funcionamiento ejecutivo [2]. También se ha documentado la relación bidireccional entre HRV y salud neurológica, señalando a la HRV como posible biomarcador objetivo de estrés psicológico, ansiedad y otras condiciones [3].

De forma complementaria, la actividad electrodermica (EDA) —regulada por el sistema nervioso simpático a través de las glándulas sudoríparas— se usa ampliamente como indicador de activación [arousal] y estrés. Una revisión sistemática sobre técnicas de aprendizaje automático para clasificación de arousal a partir de EDA encontró que las máquinas de soporte vectorial [SVM] y las redes neuronales artificiales destacan por su buen desempeño dentro de los métodos supervisados [6]. Otros trabajos han aplicado específicamente EDA para detección de estrés mediante wearables, con resultados de clasificación de precisión variable según el protocolo [7,8].

Para la adquisición de estas señales, este proyecto usa BITalino, una plataforma de bajo costo y código abierto diseñada para adquisición de bioseñales (ECG, EMG, EEG, EDA), orientada a educación y prototipado [11].

- Planteamiento del problema

Los métodos tradicionales para evaluar el estrés cognitivo (cuestionarios autorreportados, escalas psicométricas) presentan limitaciones: son subjetivos, discontinuos en el tiempo y susceptibles a sesgos de memoria o deseabilidad social. Existe una necesidad de métodos objetivos, no invasivos y en tiempo real que permitan monitorear el estado de estrés cognitivo de una persona mientras realiza tareas.

El reto técnico específico que aborda este proyecto es:

- Adquirir señales fisiológicas crudas (ECG y EDA) de forma económica y portátil.
- Procesar estas señales para obtener características fisiológicamente interpretables (HRV y EDA).
- Clasificar, a partir de dichas características, el nivel de estrés cognitivo (por ejemplo: bajo/medio/alto).
- Exponer estos resultados a un frontend ya existente (React) para su visualización en tiempo real o cuasi real.

- Propuesta de solución

Arquitectura general del sistema:

1. **Capa de adquisición:** BITalino captura señales crudas de ECG y EDA y las transmite

- (típicamente vía Bluetooth) al backend [11].
2. **Capa de procesamiento (Python 3.10+):**
 - Preprocesamiento: filtrado de ruido, detección de picos R (ECG), separación de componentes tónica/fásica (EDA).
 - Extracción de características HRV: dominio temporal (MeanRR, RMSSD, SDNN, pNN50, MeanHR) [1,4].
 - Extracción de características EDA: número de respuestas de conductancia de la piel (SCR) por minuto, amplitud, nivel tónico [6].
 3. **Capa de clasificación:** modelo (antes una comparativa entre RF, Regresión Logística y SVM, dado el buen desempeño reportado en la literatura para clasificación de arousal/estrés a partir de EDA) (6,9).
 4. **Capa de integración:** API (REST o WebSocket) que conecta el backend Python con el frontend React existente.

• Resultados

Previo al análisis, se aplicó un control de calidad automatizado a las 20 grabaciones disponibles (5 participantes, 4 por cada uno), verificando frecuencia cardíaca fisiológicamente plausible (50-140 BPM) y ausencia de saturación/desconexión del electrodo de EDA (porcentaje de muestras en 0 o en el máximo del rango ADC). Se detectó que la fase post estrés de dos participantes presentaba 79.92% y 81.03% de sus muestras de EDA en cero, consistente con desconexión parcial del electrodo, por lo que dichas grabaciones específicas fueron excluidas del análisis, conservando las 3 fases restantes de esos participantes (basal, Stroop, MIST). El resto de las 17 grabaciones no presentó anomalías.

Antes de la evaluación por features se realizó un análisis a las gráficas obtenidas de los datos adquiridos. Se evidenció un aumento de la frecuencia cardíaca durante las pruebas de Stroop y MIST respecto a las fases basales en los datos adquiridos de los participantes, consistente con una reducción de la variabilidad de la frecuencia cardíaca (HRV) asociada a activación simpática. Este patrón, observado de forma consistente en la mayoría de los sujetos, respalda la validez del protocolo experimental como inductor de estrés cognitivo medible fisiológicamente.




Figura 1. Comparación entre la frecuencia cardíaca en estado basal y situación de estrés. La frecuencia cardíaca en situación de estrés es mayor.

El dataset final quedó compuesto por 147 ventanas de 60 segundos con 50% de solapamiento (75 ventanas etiquetadas como "sin estrés" y 72 como "con estrés"), derivadas de las fases basales y

de Stroop/MIST respectivamente. De cada ventana se extrajeron 11 features: 5 de HRV en dominio temporal (MeanRR, RMSSD, SDNN, pNN50, MeanHR) y 6 de actividad electrodérmica (nivel y variabilidad de la componente tónica; conteo, tasa y amplitud de las respuestas fásicas, y variabilidad de la componente fásica). Las features de HRV en dominio de frecuencia (LF, HF, razón LF/HF) fueron excluidas por requerir ventanas continuas de al menos 5 minutos según el estándar Task Force de la ESC (1996), incompatibles con la duración de ventana utilizada.

Se entrenaron y comprobaron tres algoritmos, entre ellos SVM. Bajo el mismo esquema de validación Leave One Subject Out, en el cual cada participante fue utilizado como “conjunto” de prueba mientras el modelo se entrenaba con los 4 restantes, rotando en 5 iteraciones. Los resultados promedio se resumen en la siguiente tabla por cada modelo (Random Forest, SVM y Regresión Logística).

Métrica	Random Forest	SVM	Regresión Logística
Accuracy	0.541 ± 0.102	0.662 ± 0.179	0.713 ± 0.110
Sensibilidad / Recall	0.345 ± 0.373	0.573 ± 0.471	0.747 ± 0.387
Especificidad	0.815 ± 0.230	0.804 ± 0.246	0.647 ± 0.368
Precisión	0.425 ± 0.382	0.442 ± 0.390	0.587 ± 0.326
F1-score	0.310 ± 0.296	0.487 ± 0.404	0.639 ± 0.321
Tiempo de entrenamiento (por fold)	572.2 ms	11.9 ms	9.0 ms
Tiempo de predicción (por ventana)	870.5 µs	21.4 µs	13.5 µs

Tabla 1. Comparación de métricas de clasificación y eficiencia

El modelo de Regresión Logística obtuvo el mejor desempeño en accuracy, sensibilidad, precisión y F1-score, además de ser el modelo computacionalmente más eficiente. Random Forest, pese a ser el modelo de mayor complejidad estructural, presentó el desempeño más bajo, lo que sugiere sobreajuste dado el tamaño reducido de la muestra de entrenamiento por fold. Además, Random Forest y SVM tendieron a clasificar de forma más conservadora, mayor especificidad pero menor sensibilidad. En nuestro caso, como nos orientamos a una aplicación para alertar situación de estrés o no estrés, priorizar la sensibilidad resulta preferible.

• Conclusiones

Se pudo implementar y validar de manera integral un pipeline de detección de estrés cognitivo a partir de señales ECG y EDA capturadas con BITalino, abarcando desde la adquisición cruda hasta la clasificación mediante aprendizaje automático, con una API funcional de extremo a extremo. El protocolo experimental diseñado demostró inducir cambios fisiológicos consistentes y medibles (aumento de frecuencia cardíaca y reducción de HRV durante las fases de estrés), validando la premisa metodológica del estudio.

De los tres algoritmos evaluados, Regresión Logística ofreció el mejor balance entre desempeño de clasificación y eficiencia computacional, superando a modelos de mayor complejidad como Random Forest y SVM. Esto sugiere que, con un tamaño muestral reducido como en nuestro caso, un modelo lineal simple generaliza mejor que modelos no lineales más propensos a sobreajuste.

Sin embargo y cabe recalcar, los resultados deben interpretarse como los de un estudio piloto exploratorio, no como evidencia concluyente de un sistema listo para despliegue clínico.

Las principales limitaciones identificadas son el tamaño muestral reducido que genera alta

variabilidad entre folds de validació; datos excluidos lo que introduce asimetría en la cantidad de datos por sujeto y la exclusión de de features de HRV en dominio de la frecuencia por incompatibilidad entre nuestras ventanas de análisis y el estándar clínico de medición que es mayor a cinco minutos.

• Referencias

1. Immanuel S, Teferra MN, Baumert M, Bidargaddi N. Heart rate variability for evaluating psychological stress changes in healthy adults: a scoping review. *Neuropsychobiology*. 2023;82(4):187-202. <https://karger.com/nps/article/82/4/187/845046>
2. Nicolini P, Malfatto G, Lucchi T. Heart rate variability and cognition: a narrative systematic review of longitudinal studies. *J Clin Med*. 2024;13(1):280. <https://www.mdpi.com/2077-0383/13/1/280>
3. Arakaki X, Arechavala RJ, Choy EH, Bautista J, Bliss B, Molloy C, et al. The connection between heart rate variability (HRV), neurological health, and cognition: a literature review. *Front Neurosci*. 2023;17:1055445. <https://www.frontiersin.org/journals/neuroscience/articles/10.3389/fnins.2023.1055445/full>
4. Forte G, Favieri F, Casagrande M. Heart rate variability and cognitive function: a systematic review. *Front Neurosci*. 2019;13:710. <https://www.frontiersin.org/journals/neuroscience/articles/10.3389/fnins.2019.00710/full>
5. Peabody JE, Ryznar R, Ziesmann MT, Gillman L. A systematic review of heart rate variability as a measure of stress in medical professionals. *Cureus*. 2023;15(1):e34345. <https://www.cureus.com/articles/123303-a-systematic-review-of-heart-rate-variability-as-a-measure-of-stress-in-medical-professionals>
6. Sánchez-Reolid R, López de la Rosa F, Sánchez-Reolid D, López MT, Fernández-Caballero A. Machine learning techniques for arousal classification from electrodermal activity: a systematic review. *Sensors (Basel)*. 2022;22(22):8886. <https://www.mdpi.com/1424-8220/22/22/8886>
7. Zhu L, Spachos P, Ng PC, Yu Y, Wang Y, Plataniotis K, et al. Stress detection through wrist-based electrodermal activity monitoring and machine learning. *IEEE J Biomed Health Inform*. 2023;27(5):2155-65. <https://ieeexplore.ieee.org/document/10024755/>
8. Anusha AS, Sukumaran P, Sarveswaran V, Shyam A, Akl TJ, Preejith SP, et al. Electrodermal activity based pre-surgery stress detection using a wrist wearable. *IEEE J Biomed Health Inform*. 2020;24(1):92-100. <https://pubmed.ncbi.nlm.nih.gov/30668508/>
9. Vasile F, Vizziello A, Brondino N, Savazzi P. Stress state classification based on deep neural network and electrodermal activity modeling. *Sensors (Basel)*. 2023;23(5):2504. <https://www.mdpi.com/1424-8220/23/5/2504>
10. Sánchez-Reolid R, López MT, Fernández-Caballero A. Machine learning for stress detection from electrodermal activity: a scoping review. *Preprints*. 2020;2020110043. <https://www.preprints.org/manuscript/202011.0043>
11. Da Silva HP, Guerreiro J, Lourenço A, Fred A, Martins R. BITalino: a novel hardware framework for physiological computing. In: *Proceedings of the International Conference on Physiological*

- Biografías de autores

- **Andree Pascale Merino Contreras:** Estudiante de 8vo ciclo con interés en las áreas de ingeniería de tejidos, nanomateriales y desarrollo de dispositivos biomédicos. Busco contribuir al diseño de tecnologías médicas innovadoras que combinen biomateriales avanzados y principios de bioingeniería para mejorar las estrategias de diagnóstico y tratamiento. Me motiva la investigación en nanotecnología aplicada a la salud, desarrollo de dispositivos médicos y aplicaciones de materiales funcionales en ingeniería biomédica.
- **Francisco Hidalgo Pilco:** Estudiante de 8vo ciclo con interés en las áreas de ingeniería de tejidos e inteligencia artificial aplicada a la salud. Busco desarrollar soluciones innovadoras que integren técnicas de aprendizaje automático y análisis de datos biomédicos para apoyar el diagnóstico, monitoreo y tratamiento de enfermedades. Me motiva la investigación interdisciplinaria orientada a la medicina regenerativa, bioingeniería e implementación de herramientas de IA en aplicaciones biomédicas.
- **Kiara Muñoz Benites:** Estudiante de 8vo ciclo con interés en las áreas de ingeniería clínica, tecnología médica, dispositivos biomédicos y gestión clínica de equipos. Busco aplicar mis conocimientos en el desarrollo de soluciones que integren la ingeniería y la práctica clínica para mejorar la calidad de atención y resultados en pacientes. Me motiva la investigación interdisciplinaria y la innovación tecnológica orientada a la salud, especialmente en proyectos que vinculen diseño de dispositivos, evaluación clínica de tecnología médica y optimización de procesos hospitalarios.
- **Alexandra Lema Torres:** Estudiante de 7mo ciclo de la carrera de Ingeniería Biomédica PUCP-UPCH. Me considero una persona responsable, perseverante y comprometida con mi desarrollo académico y profesional. Me gusta aprender constantemente, trabajar en equipo y aplicar la tecnología para generar soluciones innovadoras en el área de la salud en el Perú.
- **Luana Caro Saravia:** Estudiante de 8vo ciclo con interés en las áreas de ingeniería de tejidos, señales biomédicas, ingeniería clínica y dispositivos médicos. Busco aplicar mis conocimientos en el desarrollo de soluciones que integren la ingeniería y la práctica clínica para mejorar la calidad de atención y los resultados en pacientes. Me motiva la investigación interdisciplinaria y la innovación tecnológica orientada a la salud, especialmente en proyectos relacionados con procesamiento de señales biomédicas, diseño de dispositivos médicos, evaluación clínica de tecnología y regeneración de tejidos.